编译器设计与实现文档

2025.06

1. 概述

本文档旨在详细阐述一个特定编程语言 L310 的编译器的设计与实现。该编译器包含了一个词法分析器、一个递归下降的语法分析器、符号表管理器、中间代码 (P-Code) 生成器,以及一个用于执行该中间代码的虚拟机 (VM)。此外,还提供了一个基于 Tkinter 的图形用户界面 (GUI),方便用户编写、编译运行代码并查看结果。

该编译器在设计上采用了单遍编译 (Single-Pass) 策略。这意味着它在一次从前到后的源码扫描过程中,就完成了词法分析、语法分析、语义检查和代码生成等主要工作。这得益于以下关键技术的应用:

- **递归下降解析**:语法分析器的结构直接映射了语言的 EBNF 文法,通过函数间的相 互调用来识别语法结构。
- **即时代码生成**:一旦识别出某个语法结构 (如一个表达式或一条声明语句),编译器会立即生成相应的虚拟机指令,而无需构建一个完整的中间表示 (如 AST)。

该编译器所针对的语言是一种过程式、静态作用域的语言,支持基本整型、函数、if-else、while 循环、I/O 操作,并特别地支持特定的 struct (结构体)类型、结构体数组以及结构体作为函数参数的传值调用,不支持浮点数、字符串、布尔和聚合类型直接运算。

2. 语言文法定义

语言的文法采用扩展巴科斯范式 (EBNF) 定义如下。

2.1 EBNF 文法 (以程序中通过编译的语言为准)

```
EBNF
```

```
<assign_stmt>
    | <if_stmt>
    | <while_stmt>
    <input_stmt>
    | <output_stmt>
    <func_call>
<declare_stmt> ::= "let" <ident> [ <declaration_options> ]
<declaration_options> ::= ( ":" <type_specifier> "[" <number> "]" )
           | ( ":" <type_specifier> [ "=" <expr> ] )
           | ( "=" <expr> )
<assign_stmt> ::= <designator> "=" <expr>
<if_stmt> ::= "if" "(" <bool_expr> ")" "{" <stmt_list> "}" [ "else" "{"
<stmt_list> "}" ]
<while_stmt> ::= "while" "(" <bool_expr> ")" "{" <stmt_list> "}"
<designator> ::= <ident> { ( "[" <expr> "]" ) | ( "." <ident> ) }
<func call> ::= <ident> "(" [ <arg list> ] ")"
<arg_list> ::= <expr> { "," <expr> } | <designator> { "," <designator> }
<input_stmt> ::= "input" "(" <ident> { "," <ident> } ")"
<output_stmt> ::= "output" "(" <expr> { "," <expr> } ")"
<bool_expr> ::= <expr> ( "==" | "!=" | "<" | "<=" | ">" | ">=" ) <expr>
<expr> ::= [ "+" | "-" ] <term> { ( "+" | "-" ) <term> }
<term> ::= <factor> { ( "*" | "/" ) <factor> }
<factor> ::= <designator>
     <number>
     | "(" <expr> ")"
     <func_call>
<ident> ::= <letter> { <letter> | <digit> }
<number> ::= <digit> { <digit> }
<letter> = "a" | "b" | ... | "z" | "A" | "B" | ... | "Z"
<digit> = "0" | "1" | ... | "9"
```

2.2 语言约束

除了 EBNF 文法。语言还遵循以下重要规则:

- 1. **返回语句**: func 体内部的最后一条语句必须是 return 语句,不允许提前返回。
- 2. 作用域限制: main 或普通语句块 (如 if/while 的 {...}) 内不能使用 return。
- 3. 非空语句列表: stmt list 至少包含一条语句。
- 4. 函数定义: 函数定义不能嵌套在其他函数内部, 所有函数都在程序顶层定义。
- 5. 调用顺序: 函数必须先定义后调用。
- **6. 函数传参**: 当传递数组中的一个元素作为函数参数时,该数组的索引必须是数字字面量,不能是变量。数组的索引和大小必须为非负整数。
- 7. **变量作用域**: 不允许全局变量。所有变量都在 main 或 func 的作用域内声明。变量的作用域遵循块级作用域 (lexical scoping), 内层作用域可以"遮蔽" (shadow) 外层作用域的同名变量。
- 8. **层级**: main 函数体的层级 (AR Level) 为 0, 每个 func 的层级均为 1。

3. 编译器设计与代码结构

编译器由四个核心模块组成,全部实现在 Lcompiler.py 文件中。

3.1 词法分析器 (Lexer)

- **职责**:读取源代码文本,将其分解为一系列的词法单元 (Token)。
- **实现**: Lexer 类通过扫描输入字符串,识别出关键字(如 program, func, if)、标识符、数字、操作符(如 +, ==, .)和界符(如 (, {,;),它能够自动跳过空格、换行符和单行注释(//)。

3.2 符号表 (Symbol Table)

- 职责:存储程序中所有标识符 (变量、函数、结构体定义)的信息。
- **实现**: SymbolTable 和 Symbol 类协同工作。
 - Symbol 类表示一个符号,包含其 **名称(name)、类别(kind)** (如 var, proc, struct_def)、**类型信息(type)**、作用域层级(block_level, ar level) 和 在活动记录中的地址(addr) 等关键信息。
 - SymbolTable 管理所有符号,提供添加和查找功能。它支持嵌套作用域, 能够根据当前的 **作用域名称 (scope_name)** 和 **块级别 (block_level)** 正确解析标识符。
 - 它还专门管理 struct 的定义,包括其字段、每个字段的偏移量和总大小, 为复杂数据类型的内存布局和访问提供支持。

• ar_level 与 block_level 的含义:

- ar_level (Activation Record Level): 代表**函数的静态嵌套深度**。它被用来计算访问非局部变量时的层级差 L。在本编译器中,由于不允许函数嵌套定义,main 函数在 ar_level = 0 执行,而所有顶层 func 函数都在 ar_level = 1 执行。这个值在进入函数解析时确定,并在整个函数体内保持不变。
- block_level (Block Level): 代表同一函数内部的代码块 ({...}) 嵌套层级。它用于处理变量的"遮蔽" (shadowing), 例如, 一个函数体的第一层是 block_level = 1, 其内部的 if 或 while 语句会创建block_level = 2 的新作用域。当查找变量时,编译器会从当前的block_level 向外 (递减)搜索,从而找到最近的定义。

• 同名变量 (遮蔽) 的处理:

- **存储方式**: 当编译器遇到一个变量声明 (如 let x) 时,它会使用 (name, scope_name, block_level) 这个三元组作为键来在符号表中创建一个唯一的 Symbol 条目,例如,在 main 中 (block_level=1)声明的 let num 和其内部 if 语句中 (block_level=2)声明的 let num 会成为符号表里两个独立的条目,分别对应 ('num', 'main', 1) 和 ('num', 'main', 2)。
- 地址(A 值)分配:每个被遮蔽的变量都是一个全新的变量,因此会通过 get_next_addr_offset 分配一个新的、独立的运行时栈地址 (相对于 bp 的偏移量),即它们的 A 值 (addr 属性) 是不同的。
- **访问时的 L 和 A 值计算**: 当代码中使用一个变量名时, lookup_symbol 函数从当前 block_level 开始向 Ø 搜索。它会首先找到最内层的同名变量。生成 lod 或 sto 指令时, A 值就取自这个最内层符号的 addr 属性。 L 值则根据 current_ar_level symbol.ar_level 计算得出。这一机制确保了变量遮蔽的正确实现。

3.3 语法分析与代码生成 (ParserAndGenerator)

- **职责**: 这是编译器的核心。它采用 递归下降 (Recursive Descent) 的方法进行 语法分析,并在分析过程中同步生成虚拟机的目标代码 (P-Code)。
- **实现**: ParserAndGenerator 类:
 - 1. 从 Lexer 获取 Token。
 - 2. 拥有一系列与文法规则对应的 _parse_* 方法 (如 _parse_stmt, _parse_expr)。
 - 3. 在语法分析的同时,与 SymbolTable 交互, 填充和查询符号信息。
 - 4. 调用 _emit 方法生成 P-Code 指令, 并将其存入一个列表。
 - 5. 处理地址回填, 例如, if 或 while 语句中的跳转地址在解析完其代码块后才能确定。

• 实地址回填 (A 值) 的计算逻辑:

对于需要前向跳转的控制流语句 (如 if, while), 目标地址在生成跳转指令时是未知的。编译器采用"回填"技术解决此问题:

- 1. 生成占位指令: 当解析到 if 或 while 的条件时,会立即生成一条 jpc 指令。此时,由于目标地址未知,指令的 A 值会被设置为一个临时的、唯一的字符串标签 (如 _while_end_15) 作为占位符。同时,保存这条指令在代码列表中的索引。
- 2. 标记目标地址: 当解析器到达跳转的目标位置时 (例如 while 循环体的末尾), 它会调用 _mark_label 方法。该方法将当前的指令计数器 (PC) 值与该标签关联起来, 存入一个字典中。
- 3. 地址修补:解析器随后调用 _patch_jump_address 方法,使用之前保存的指令索引找到那条 jpc 指令,并将其 A 值的占位符字符串替换为最终解析出的目标 PC 整数值,这个过程在解析完整个程序后的一个最终处理阶段完成,确保所有标签都转换为确切的地址。

3.4 虚拟机 (VM)

- 职责: 执行由代码生成器产生的 P-Code 指令序列。
- 实现: VM 类模拟一个基于栈的计算机。
 - **数据栈 (stack)**: 用于存储操作数、变量、函数调用的控制信息等。

○ 寄存器:

- pc (Program Counter): 指向下一条要执行的指令。
- bp (Base Pointer): 指向当前活动记录 (Activation Record) 的基地址。
- sp (Stack Pointer): 指向栈顶。
- 执行循环: run 方法循环读取 pc 指向的指令并执行, 直到程序结束。
- **活动记录 (AR)**:每次函数调用都会在栈上创建一个新的 AR,用于存放参数、局部变量和控制链 (静态链、动态链、返回地址)。

4. 核心: P-Code 虚拟机指令集

P-Code 是一种为栈式虚拟机设计的中间代码。每条指令由一个操作码 (op) 和两个参数 (L 和 A) 组成。

4.1 指令格式

- {op, l, a, comment}
 - op: 指令操作码 (字符串)。
 - 1: 层级差 (Level difference)。一个整数,用于在静态作用域链上查找 变量。
 - a: 地址或操作数 (Address/Argument)。一个整数或标签,具体含义取决于 op。
 - o comment: 注释,用于解释该指令的生成目的,便于调试。

4.2 活动记录 (Activation Record) 结构

要理解 L 的含义, 首先要了解函数调用时在栈上创建的活动记录 (AR) 的结构。当调用一个函数时, 其 AR 从新的 bp 处开始, 结构如下:

- stack[bp]: **静态链 (Static Link, SL)** 指向定义该函数的上一层作用域的 AR 的基地址。
- stack[bp+1]: **动态链 (Dynamic Link, DL)** 指向调用者 (caller) 的 AR 的基地址。
- stack[bp+2]: **返回地址 (Return Address, RA)** 调用结束后应返回到的指令 地址 (PC)。
- stack[bp+3]: **参数个数 (NARGS)** 传递给该函数的标量参数总数。
- stack[bp+4]...: 参数和局部变量 按照符号表中分配的地址 (偏移量) 存放。

4.3 指令详解

操作码 (op)	L (Level)	A (Argument)	描述
lit	0	value	Literal: 将立即数 value 压入栈顶。
lod	L	offset	Load: 从 (L, offset) 指定的地址加载一个值到栈顶。计算方法: 首先通过 L 沿着静态链回溯 L 次找到正确的 AR 基地址base_addr, 然后加载 stack[base_addr + offset] 的值。

sto	L	offset	Store:将栈顶的值存入 (L, offset) 指定的地址。计算方法同 lod, 但操作是存储。
cal	L	func_pc	Call: 调用函数。L 是调用者与被调用函数 定义处的层级差。func_pc 是被调用函数的 入口地址。执行时,会在栈上建立新的 AR (SL, DL, RA), 然后 pc 跳转到 func_pc。
int	0	size	Increment Top: 在当前 AR 中为局部变量 预留 size 个存储单元的空间,即 sp = bp + size。
jmp	0	target_pc	Jump: 无条件跳转。将 pc 设置为 target_pc。
jpc	0	target_pc	Jump on Condition: 弹出栈顶的值。如果 为 0 (false), 则跳转到 target_pc。
opr	0	op_code	Operator: 执行操作, 由 op_code 决定: - 0: Return - 从函数返回。恢复调用者的pc, bp, sp, 并将返回值放在新的栈顶。 - 2-5: +, -, *, / - 弹出两个操作数, 计算后将结果压栈。 - 8-13: ==, !=, <, >=, >, <= - 弹出两个操作数, 比较后将布尔结果 (1 或 0) 压栈。 - 14: Output - 弹出栈顶值并输出。 - 15: (无操作) - 用于在输出后格式化。 - 16: Pop - 弹出并丢弃栈顶值 (用于处理函数调用后未使用的返回值)。
lods	L	0	Load Indirect: 间接加载。用于访问 a[i] 或 s.f 这样的复杂左值。执行时,它会先从 栈 顶 弹 出 一 个 计 算 好 的 偏 移 量 computed_offset, 然后通过 L 找到基地址 base_addr, 最终加载 stack[base_addr + computed_offset] 的值并压入栈顶。
stos	L	0	Store Indirect: 间接存储。与 lods 类似,但它会弹出值和偏移量,将值存入stack[base_addr + computed_offset]。
inp	L	offset	Input:从用户获取一个整数输入,并将其存入(L, offset)指定的地址。

4.4 层级差1的说明

L (Level)的值用于处理不同静态嵌套深度函数之间的非局部变量访问。它帮助虚拟机沿着静态链(由活动记录中的静态链接 SL 构成)向上查找声明变量的那个函数的活动记录。 l_val 指示向上跳多少级静态链。它的值是通过公式 L = current_ar_level - symbol_ar_level 计算得出的,其中 current_ar_level 是当前代码执行点的 AR 层级, symbol_ar_level 是被访问变量或被调用函数在其定义时的 AR 层级。

• cal 指令的 L 值:

- 当 L = 1 时: 当一个函数 A (执行在 ar_level=1) 调用另一个函数 B
 (定义在 ar level=0) 时. cal 指令的 L 为 1 0 = 1。
- **当 L = 0 时**: main 函数 (执行在 ar_level=0) 调用一个函数 (定义在 ar level=0), cal 指令的 L 为 0 0 = 0。
- lod/sto 指令的 L 值:本语言的作用域规则有一个重要特点:函数只能访问自身的局部变量或 main 作用域中的变量,不允许访问其他"兄弟"函数的内部变量,这一设计简化了静态链的查找。同一函数内的不同块,即使嵌套,仍然属于同一个函数的静态层级 (AR Level)。
 - **当 L = 1 时**: 当一个函数 (执行在 ar_level=1) 需要访问在 main 中 定义的变量 (定义在 ar_level=0) 时, lod/sto 指令的 L 为 1 0 = 1。
 - **当 L = 0 时**: 当一个函数 (执行在 ar_level=1) 访问自己的局部变量或 参数 (也定义在 ar_level=1) 时, lod/sto 指令的 L 为 1 1 = 0。

综上,由于语言不支持函数嵌套定义,L 的值只可能是 0 或 1,它精确地反映了当前执行 点与目标符号定义点之间的静态层级关系。

4.5 地址或操作数 a 的说明

A (Argument) 的值根据指令类型有不同的计算方法。

- cal 1 a 指令中 A 的计算: A 是被调用函数的入口地址。在代码生成阶段,解析器从符号表中查找函数符号,获取其 addr 属性,这个 addr 就是一个指向函数第一条指令的标签。在最终回填阶段,这个标签会被替换为具体的 PC 值,成为 cal 指令的 A 值。
- **函数调用时,加载参数的 lod 指令中 A 为负数的原因**: 这发生在被调用函数 (callee) 的内部,目的是将调用者 (caller) 压入栈的**实参**复制到自己的**形参**存储区。调用栈是动态的,新分配区域的生命周期仅限于函数调用期间。
 - 1. 调用过程: Caller 先将所有参数压栈, 然后执行 cal 指令。
 - 2. **栈帧切换**: cal 指令执行后, VM 切换上下文, 新的 bp 指向新栈帧的基址。 之前由 Caller 压入的参数位于新 bp 的下方, 因此需要用负向偏移量。
 - 3. A 值计算: 在被调用函数的序言 (prologue) 中,编译器生成一系列 lod 指令。A 的值从 -N 开始 (N 是标量参数总数),依次递增。例如,第一个参数的地址是 bp-N,第二个是 bp-N+1,以此类推。L 值为 0,因为这些参数就在当前 bp 的下方,无需跨越静态链。
- 图示:函数调用时参数的负向偏移量访问:在被调用函数 (callee) 内部,需要使用 lod 指令将调用者 (caller) 压入栈的实参复制到自己的形参存储区。由于此时新的 bp 已经指向了 callee 栈帧的基址,而实参位于其下方,因此必须使用负向偏移量来访问。

```
func calc(a, b)
   let temp_val;let final_val;
   temp_val = a + b;
final_val = temp_val * b;
   return final val;
1. cal 指令执行前 (Caller 压入参数后)
         | <-- 新的 sp (压入最后一个参数后)
| main vars |
.
此时,存放 5 和 3 的这部分空间是一个临时的"参数传递区"。它在逻辑上既不属于 main 的局部变量区,也不属于即将被调用的函数的局部变量区。
            <-- SP (栈顶, 为局部变量分配空间后)
(bp+8) <-- final_val 的地址</p>
final_val |
              (bp+7) <-- temp_val 的地址
temp_val
              (bp+6) <-- ret 的地址
              (bp+5) <-- 形参 b 的地址
(bp+4) <-- 形参 a 的地址
 RΔ
              (bp+2) <-- 返回地址 (Return Address)
              (bp+1) <-- 动态链 (Dynamic Link)
l dl
             (bp+0) <-- 静态链 (Static Link), 新的 BP 指向此处 (bp-1) <-- lod 0 -1 读取的值 (第二个实参) (bp-2) <-- lod 0 -2 读取的值 (第一个实参)
当被调用函数执行 opr 0, 0 指令返回时,虚拟机会根据约定精确地恢复调用者的 bp,并将 sp 指针重置到参数区域之下。
```

5. 运行方式与图形用户界面 (GUI)

通过 GUI.py 启动的图形界面为用户提供了一个集成开发环境。

5.1 界面布局

GUI 界面 (CompilerGUI 类) 分为左右两个可调整的主窗格:

- 左侧面板 (垂直分割):
 - 源代码区: 用户在此编写和编辑代码。
 - 符号表 & 结构体定义区: 编译成功后, 详细显示符号表和结构体布局信息。
 - 底部标签页:
 - 状态/错误:显示编译和运行过程中的状态信息或详细的错误回溯。
 - 程序输出 (ANS) : 显示由 output 语句产生的程序运行结果。
 - 控制按钮区:
 - 编译并运行:核心按钮,触发整个编译和执行流程。
 - 清空:清空所有文本框。
 - +/-: 调整界面字体大小。
- 右侧面板:
 - **生成的 VM 代码区**:编译成功后,显示生成的 P-Code 指令及其注释。

5.2 运行流程

- 1. 用户在"源代码区"输入代码。
- 2. 点击"编译并运行"按钮。
- 3. GUI 调用 compile_and_run 方法:
 - a. 清空旧的输出内容。
 - b. 实例化 Lexer, ParserAndGenerator。
 - c. 调用 parser.parse(), 此过程会完成词法分析、语法分析、符号表构建和 P-Code 生成。

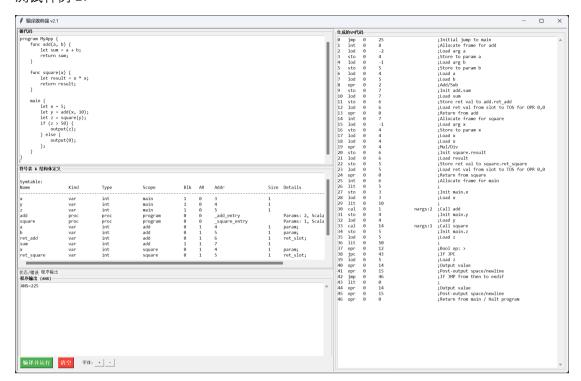
- d. 如果编译成功:
 - i. 将生成的 P-Code 格式化并显示在"VM 代码区"。
 - ii. 捕获 symtable.display() 的输出并显示在"符号表区"。
 - iii. 实例化 VM, 并将生成的 P-Code 传入。
 - iv. 将 GUI 的输入处理函数 gui_input_handler 设置给 VM 实例, 以便在执行 inp 指令时弹出对话框。
 - v. 调用 vm.run() 执行代码。
 - vi. 将 VM 的输出结果显示在"程序输出 (ANS)"标签页。
 - vii. 在"状态"区显示"编译和执行成功"。
- e. 如果编译或运行过程中出现任何异常:
 - i. 捕获异常信息和完整的 traceback。
 - ii. 将详细的错误信息显示在"状态/错误"标签页。

6. 样例分析

samples.ipynb 中提供了多个测试用例。每个用例都旨在测试编译器的特定功能。

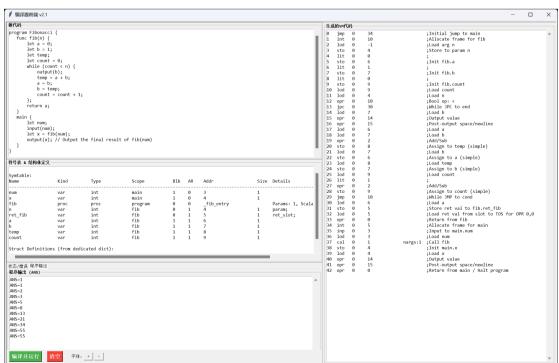
- MyApp: 测试基本的函数定义、调用、if-else 分支和 output 语句。
- Fibonacci: 测试 while 循环、变量的连续赋值和 input 功能。
- GCD: 测试更复杂的 while 循环逻辑和算术运算 (特别是除法和减法)。
- Factorial: 核心测试点是 单一出口递归函数调用。检验 cal 和 opr 0 指令能否正确构建和拆除多层活动记录。
- ChainedCallTest:测试 **函数链式调用**,检验编译器的调用机制和运行时的栈管理是否正确,并验证 cal 指令的 L 值的动态计算。
 - 多层活动记录:测试调用链能否正确创建和销毁各自的活动记录。
 - 返回值传递: 检验内层函数 (add_offset) 的返回值能否被其中间调用者 (calculate_series) 正确接收和使用,并最终将计算结果返回给顶层调用者 (main)。
- Shadowing: 重点测试 词法作用域 和 变量遮蔽。验证编译器能否在不同块级作用 域 (if, else, while 内部) 正确创建和查找变量, lod/sto 指令的 L 参数是 否计算正确。
- MyShape: 测试 结构体 (struct) 功能,包括:
 - 声明 struct 类型的变量 (pt1) 和 struct 类型的数组 (colors)。
 - 通过 . 和 [] 访问成员 (如 pt1.x, colors[i].r), 检验 lods/stos 间接寻址指令的正确性。
 - 将 struct 作为参数**按值传递**给函数,检验复杂数据类型在函数调用时的 复制和访问机制。
- StudentGrades: 进一步验证 结构体数组 和 将结构体作为参数 的功能,特别是 当结构体内部包含数组成员时 (s.scores[i])。
- PointOperations:测试结构体,包含 嵌套的复杂数据结构。
 - 测试对深层嵌套成员 (如 sh.points[i].x) 的访问, 高要求检验编译器 的地址计算和 lods/stos 指令的生成逻辑。
 - 检验符号表对复杂类型大小和偏移的计算能力。
- BubbleSortTest: 测试 冒泡排序 算法和将 数组作为结构体成员 进行参数传递。
- DivideByZeroTest: 测试 出错和异常管理。

测试样例 1:

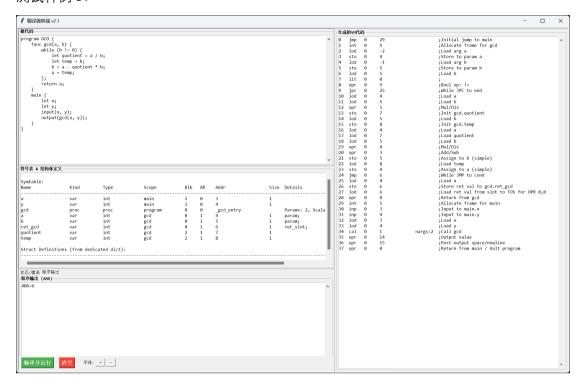


测试样例 2:

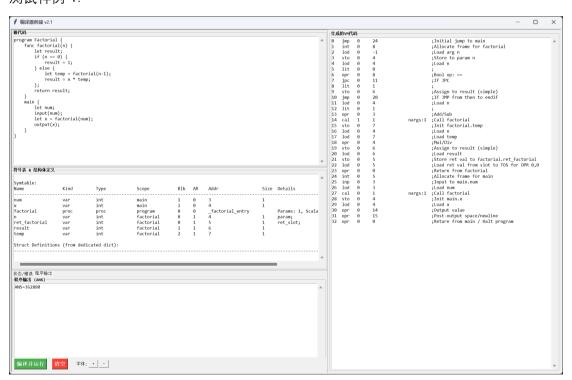




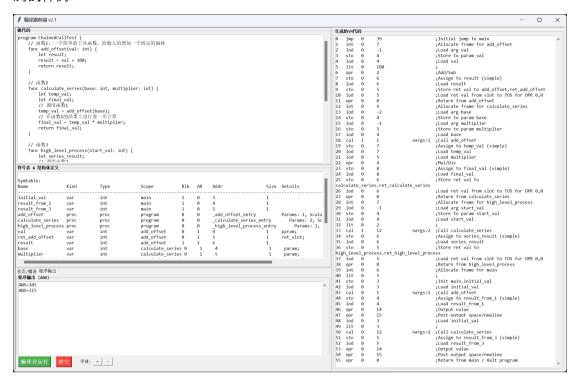
测试样例 3:



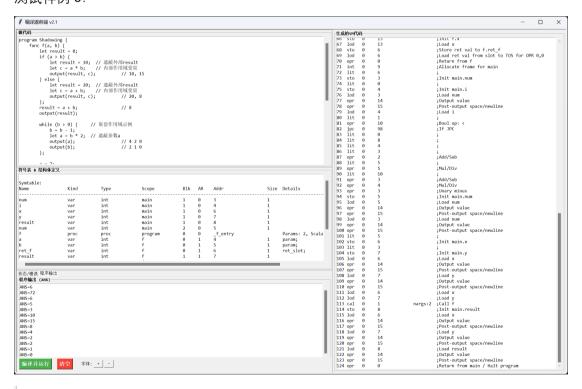
测试样例 4:



测试样例 5:

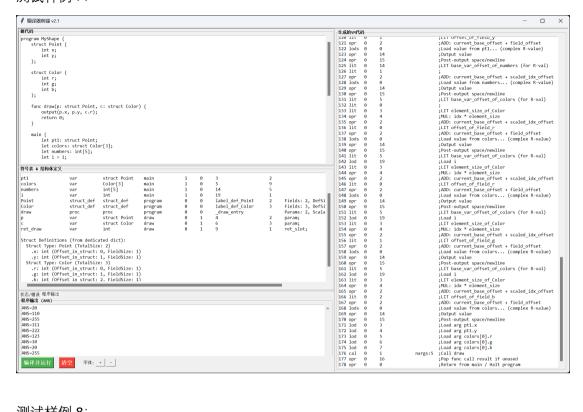


测试样例 6:

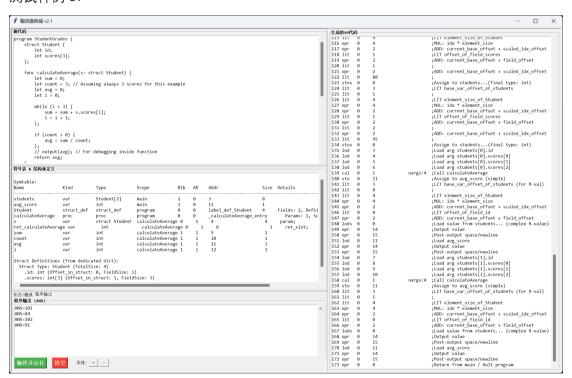


ANS=10 ANS=15 ANS=8 ANS=4 ANS=2 ANS=2 ANS=1 ANS=0 ANS=0 ANS=6 ANS=5

测试样例 7:



测试样例 8:



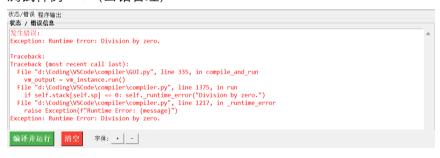
测试样例 9:



测试样例 10:



测试样例 11: (出错管理)



7. 补充

增加了对数组越界访问的异常检测和管理。

- **新定义**: 一条新的 P-Code 指令 chk (check)。格式: chk 0 size。功能: 该指令执行时,会检查当前栈顶的值 (即数组访问的索引 index),判断它是否在 [0, size-1] 的有效范围内。如果不在,就抛出运行时错误;否则程序继续执行。发射方式:在使用数组(读和写)的两个路径上都加入该检查逻辑。
- **澄清**: 该编译器没有硬编码单个数组的最大长度, 而是通过虚拟机的总栈空间限制。在 Lcompiler.py 的 VM 类中, 虚拟机的栈被初始化为一个固定大小的数组: self.stack = [0] * 8192, 超出后会发生运行时错误。